

Data handling section

SAMSUNG Data Science Academy

최성철 교수 Director of TEAMLAB

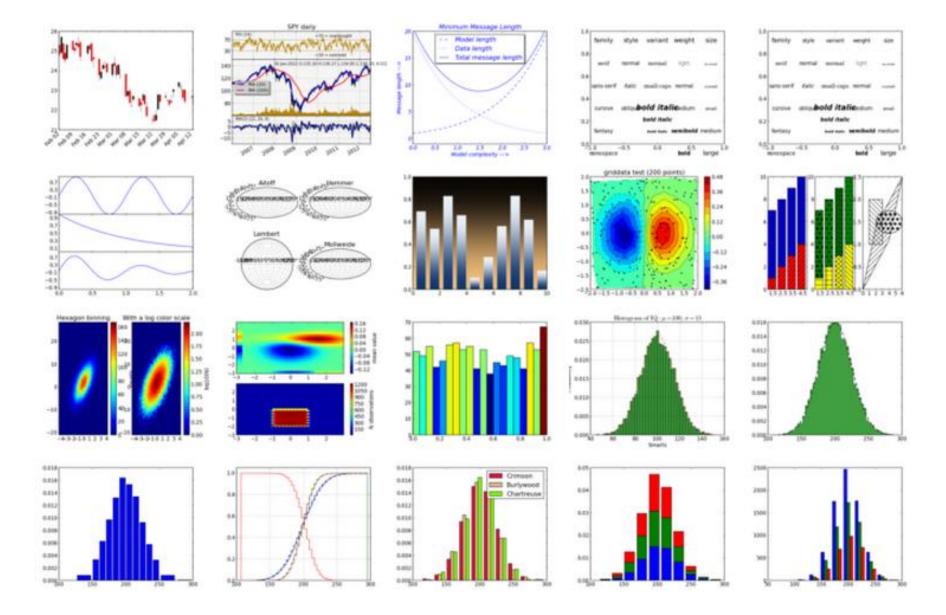


우리의 데이터는 어떻게 생겼을까?

Visualization 데이터 시각화

파이썬의 대표적인 시각화 도구

matpletlib



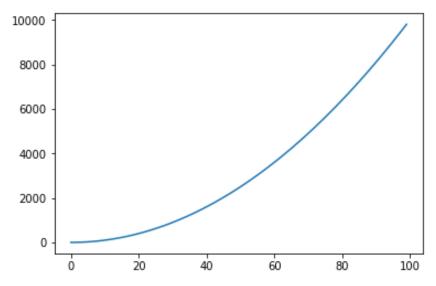
다양한 graph 지원 Pandas 연동!

기본사용법

- pyplot 객체를 사용하여 데이터를 표시
- pyplot 객체에 그래프들을 쌓은 다음 flush

```
import matplotlib.pyplot as plt

X = range(100)
Y = [value**2 for value in X]
plt.plot(X, Y)
plt.show()
```



- 최대 단점 argument를 kwargs 받음,
- 고정된 argument가 없어서 alt+tab으로 확인이 어려움

```
Signature: plt.plot(*args, **kwargs)
Docstring:
Plot lines and/or markers to the
:class:`~matplotlib.axes.Axes`. *args* is a variable length
argument, allowing for multiple *x*, *y* pairs with an
optional format string. For example, each of the following is
legal::

    plot(x, y)  # plot x and y using default line style and color
    plot(x, y, 'bo') # plot x and y using blue circle markers
    plot(y)  # plot y using x as index array 0..N-1
    plot(y, 'r+') # ditto, but with red plusses
```

- Graph는 원래 figure 객체에 생성됨
- pyplot 객체 사용시, 기본 figure에 그래프가 그려짐

```
X_1 = range(100)
Y_1 = [np.cos(value) for value in X]

X_2 = range(100)
Y_2 = [np.sin(value) for value in X]

plt.plot(X_1, Y_1)
plt.plot(X_2, Y_2)
plt.show()
```

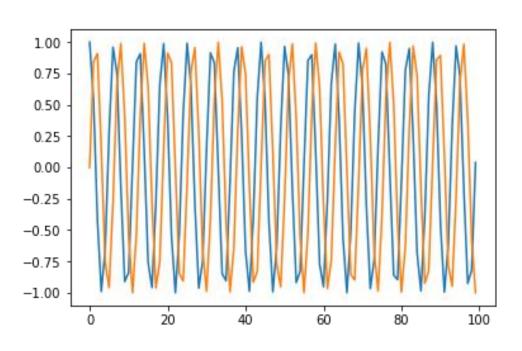
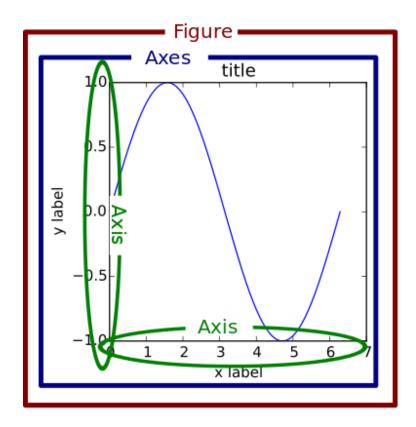


Figure & Axes

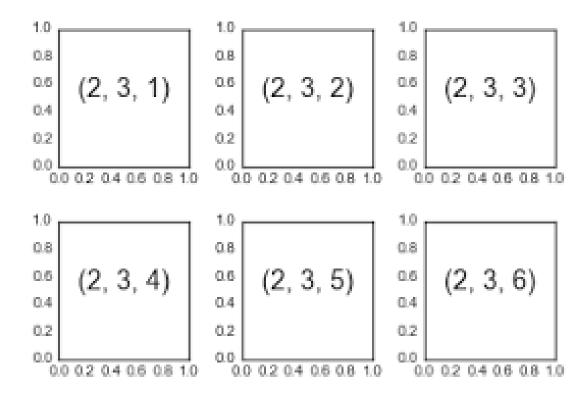
- Matplotlib는 Figure 안에 Axes로 구성
- Figure 위에 여러 개의 Axes를 생성



```
fig = plt.figure() # figure 반환
fig.set_size_inches(10,5) # 크기지정
ax_1 = fig.add_subplot(1,2,1) # 두개의 plot 생성
ax_2 = fig.add_subplot(1,2,2) # 두개의 plot 생성
ax_1.plot(X_1, Y_1, c="b")100
ax_2.plot(X_2, Y_2, c="g")0.75
plt.show() # show & flush 0.50
                            0.25
                                                     0.25
                            0.00
                                                     0.00
                            -0.25
                            -0.50
                                                     -0.50
                            -0.75
                            -1.00
```

subplots

- Subplot의 순서를 grid로 작성



Set color

- Color 속성을 사용
- Float → 흑백, rgb color, predefined color 사용

```
plt.plot(X_1, Y_1, color="#eeefff")
plt.plot(X 2, Y 2, color="r")
                         200
plt.show()
                         175
                         150
                         125
                         100
                          75
                          50
                          25
                                            60
```

Set linstyle

- Is 또는 linestyle 속성 사용

```
plt.plot(X_1, Y_1, c="b", linestyle="dashed")
plt.plot(X_2, Y_2, c="r", ls="dotted")
                        200
plt.show()
                        175
                        150
                        125
                        100
                        75
                        50
                        25
                                20
                                      40
                                           60
                                                80
                                                     100
```

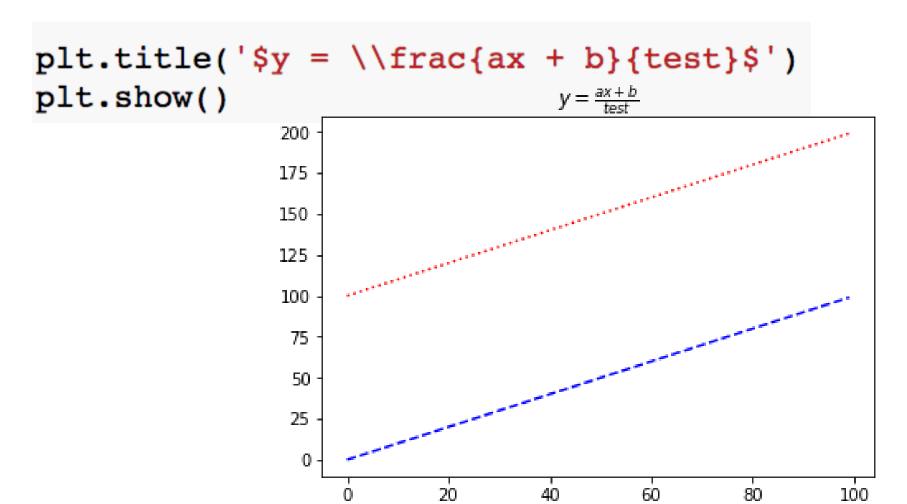
Set title

- Pyplot에 title함수 사용, figure의 subplot별 입력 가능

```
plt.plot(X 1, Y 1, color="b", linestyle="dashed")
plt.plot(X_2, Y_2, color="r", linestyle="dotted")
                                         Two lines
plt.title("Two lines")
                           175
plt.show()
                           150
                           125
                            100
                            75
                            50
                            25
                                    20
                                         40
                                              60
                                                   80
                                                        100
```

Set title

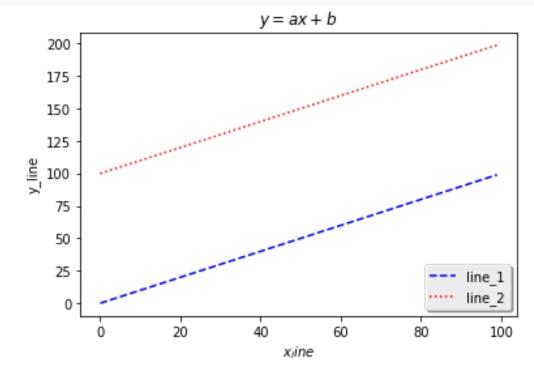
- Latex 타입의 표현도 가능 (수식 표현 가능)



Set legend

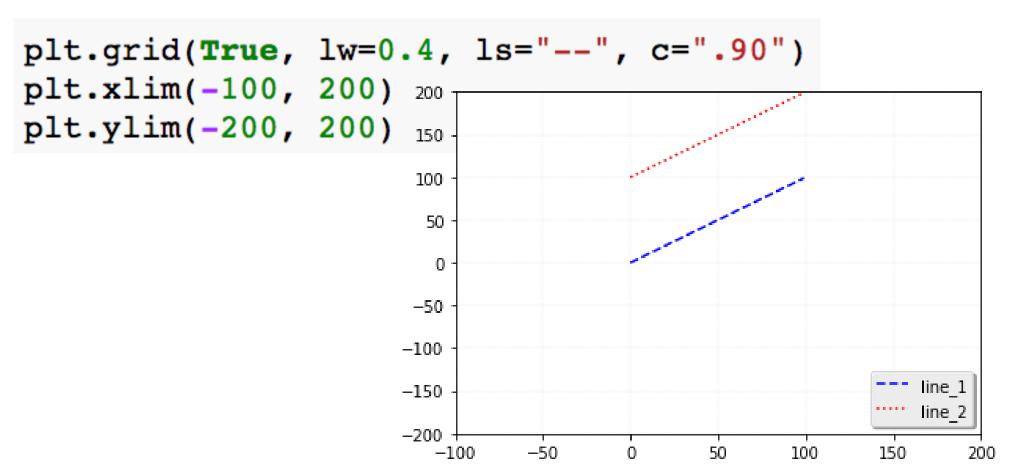
- Legend 함수로 범례를 표시함, loc 위치등 속성 지정

```
plt.plot(X_1, Y_1, color="b", linestyle="dashed", label='line_1')
plt.plot(X_2, Y_2, color="r", linestyle="dotted", label='line_2')
plt.legend(shadow=True, fancybox=True, loc="lower right")
```



Set grid & xylim

- Graph 보조선을 긋는 grid와 xy축 범위 한계를 지정



Matplotlib Graph

Scatter

- scatter 함수 사용, marker: scatter 모양지정

```
data 1 = np.random.rand(512, 2)
data_2 = np.random.rand(512, 2)
plt.scatter(data 1[:,0], data 1[:,1], c="b", marker="x")
plt.scatter(data_2[:,0], data_2[:,1], c="r", marker="^")
                           1.0
plt.show()
                            0.8
                            0.6
                            0.4
                            0.2
                            0.0
                                                       0.6
                                                                      1.0
                                0.0
                                        0.2
                                               0.4
                                                              0.8
```

Scatter

N = 50

- s: 데이터의 크기를 지정, 데이터의 크기비교가능

```
x = np.random.rand(N)
y = np.random.rand(N)
colors = np.random.rand(N)
area = np.pi * (15 * np.random.rand(N))**2
plt.scatter(x, y, s=area, c=colors, alpha=0.5)
plt.show()
                              1.0
                              0.8
                              0.6
                              0.4
                              0.2
                              0.0
                                      0.2
                                            0.4
                                                  0.6
                                                        0.8
```

Bar chart

Bar 함수 사용

```
40
                               30
data = [[5., 25., 50., 20.],
        [4., 23., 51., 17],
                               10
        [6., 22., 52., 19]]
                                         1.0
                                            1.5
                                                2.0
                                                    2.5
                                     0.5
                                                       3.0
X = np.arange(4)
plt.bar(X + 0.00, data[0], color = 'b', width = 0.25)
plt.bar(X + 0.25, data[1], color = 'g', width = 0.25)
plt.bar(X + 0.50, data[2], color = 'r', width = 0.25)
plt.xticks(X+0.25, ("A", "B", "C", "D"))
plt.show()
```

50

Bar chart

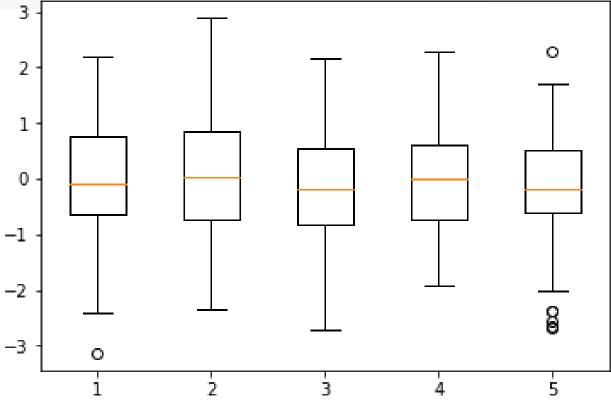
```
160
                                 140
                                 120
                                  100
                                  80
                                  60
                                  40
color_list = ['b', 'g', 'r']
                                  20
data_label = ["A","B","C"]
                                          0.5 1.0
                                                 1.5
                                   -0.5 0.0
X = np.arange(data.shape[1])
for i in range(data.shape[0]):
    plt.bar(X, data[i], bottom = np.sum(data[:i], axis=0),
             color = color_list[i], label=data_label[i])
plt.legend()
plt.show()
```

histogram

```
X = np.random.randn(1000)
plt.hist(X,bins=100)
plt.show()
               30
               25
               20
               15
               10
               5 -
                            -1
                                ò
```

boxplot

```
data = np.random.randn(100,5)
plt.boxplot(data)
plt.show()
```



matplotlib with pandas

pandas matplotlib

- matplotlib를 사용한 그래프 지원
- Dataframe, series별로 그래프 작성 가능

| | CRIM | ZN | INDUS | CHAS | NOX | RM | AGE | DIS | RAD | TAX | PTRATIO | В | LSTAT | MEDV |
|---|---------|------|-------|------|-------|-------|------|--------|-----|-------|---------|--------|-------|------|
| 0 | 0.00632 | 18.0 | 2.31 | 0 | 0.538 | 6.575 | 65.2 | 4.0900 | 1 | 296.0 | 15.3 | 396.90 | 4.98 | 24.0 |
| 1 | 0.02731 | 0.0 | 7.07 | 0 | 0.469 | 6.421 | 78.9 | 4.9671 | 2 | 242.0 | 17.8 | 396.90 | 9.14 | 21.6 |
| 2 | 0.02729 | 0.0 | 7.07 | 0 | 0.469 | 7.185 | 61.1 | 4.9671 | 2 | 242.0 | 17.8 | 392.83 | 4.03 | 34.7 |
| 3 | 0.03237 | 0.0 | 2.18 | 0 | 0.458 | 6.998 | 45.8 | 6.0622 | 3 | 222.0 | 18.7 | 394.63 | 2.94 | 33.4 |
| 4 | 0.06905 | 0.0 | 2.18 | 0 | 0.458 | 7.147 | 54.2 | 6.0622 | 3 | 222.0 | 18.7 | 396.90 | 5.33 | 36.2 |

Boston House Price Dataset

X 변수 13개

Y 변수

| [01] CRIM | 자치시(town) 별 1인당 범죄율 |
|--------------|---|
| [02] ZN | 25,000 평방피트를 초과하는 거주지역의 비율 |
| [03] INDUS | 비소매상업지역이 점유하고 있는 토지의 비율 |
| [04] CHAS | 찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0) |
| [05] NOX | 10ppm 당 농축 일산화질소 |
| [06] RM | 주택 1가구당 평균 방의 개수 |
| [07] AGE | 1940년 이전에 건축된 소유주택의 비율 |
| [08] DIS | 5개의 보스턴 직업센터까지의 접근성 지수 |
| [09] RAD | 방사형 도로까지의 접근성 지수 |
| [10] TAX | 10,000 달러 당 재산세율 |
| [11] PTRATIO | 자치시(town)별 학생/교사 비율 |
| [12] B | 1000(Bk-0.63)^2, 여기서 Bk는 자치시별 흑인의 비율을 말함. |
| [13] LSTAT | 모집단의 하위계층의 비율(%) |
| [14] MEDV | 본인 소유의 주택가격(중앙값) (단위: \$1,000) |

http://www.dator.co.kr/ctg258/textyle/1721307

http://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html

pandas matplotlib

- 데이터간의 상관관계를 볼 때 scatter graph 사용 가능

```
fig = plt.figure()
ax = []
for i in range(1,5):
    ax.append(fig.add subplot(2,2,i))
ax[0].scatter(df data["CRIM"], df data["MEDV"])
ax[1].scatter(df_data["PTRATIO"], df_data["MEDV"])
ax[2].scatter(df data["AGE"], df data["MEDV"])
ax[3].scatter(df_data["NOX"], df_data["MEDV"])
plt.show()
                                                        12.5 15.0 17.5 20.0 22.5
                                       20
                                                         0.4
```

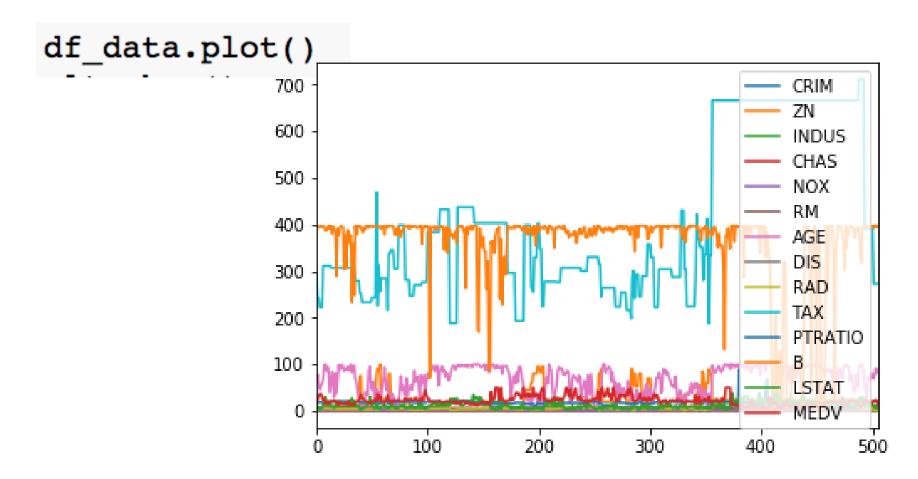
pandas matplotlib

- matplotlib의 꾸미기 함수 그대로 사용함

```
ax[0].scatter(df data["CRIM"], df data["MEDV"], color="b", label="CRIM")
ax[1].scatter(df_data["PTRATIO"], df_data["MEDV"], color="g" )
ax[2].scatter(df data["AGE"], df data["MEDV"] )
ax[3].scatter(df_data["NOX"], df_data["MEDV"])
plt.subplots adjust(wspace=0, hspace=0)
                                             CRIM
ax[0].legend()
ax[0].set title("CRIM")
                                    30
                                                     30
                                    20
                                   10
                                    50
                                    30
                                    20
                                   10
                                                                   0.8
```

pandas matplotlib - plot function

- plot 함수를 사용하면 전체 데이터의 graph를 그림



pandas matplotlib - plot function

- kind : plot 종류
- x: x축 컬럼
- y:y축 컬럼

import matplotlib.pyplot as plt import pandas as pd

df.plot(kind='scatter',x='num_children',y='num_pets',color='red')
plt.show()

http://queirozf.com/entries/pandas-dataframe-plot-examples-with-matplotlib-pyplot

pandas matplotlib

```
25
                                   15
                                   10
fig = plt.figure()
fig.set size inches(10,5)
ax 1 = fig.add subplot(1,2,1)
ax 2 = fig.add subplot(1,2,2)
ax 1.plot(df data["MEDV"])
ax 2.hist(df data["MEDV"], bins=50)
ax 1.set title("House price MEDV")
ax 2.set title("House price MEDV")
```

House price MEDV

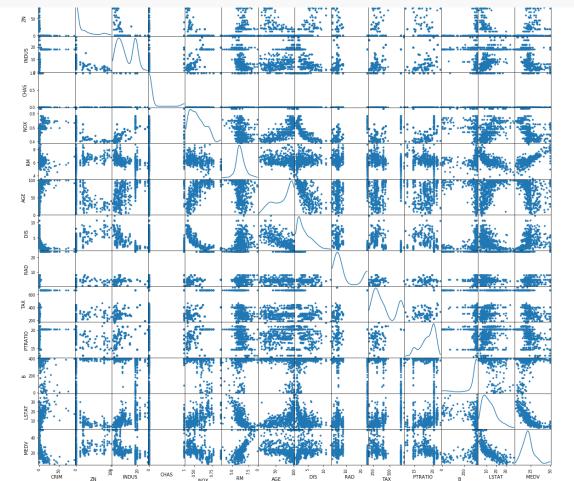
House price MEDV

Scaled boxplot

```
from sklearn.preprocessing import StandardScaler
               std scaler = StandardScaler()
               scale data = std scaler.fit transform(df_data)
               fig = plt.figure()
               ax = fig.add subplot(1,1,1)
               ax.boxplot(scale data, labels=df data.columns)
               fig.set size inches(18.5, 10.5)
CRIM
        INDUS
            CHAS
                 NOX
                     RM
                         AĠE
                             DIS
                                  RAD
                                      TAX
                                          PTRATIO
                                                  LSTAT
                                                       MEDV
```

Scatter matrix

```
pd.scatter_matrix(df_data, diagonal="kde", alpha=1, figsize=(20, 20))
plt.show()
```

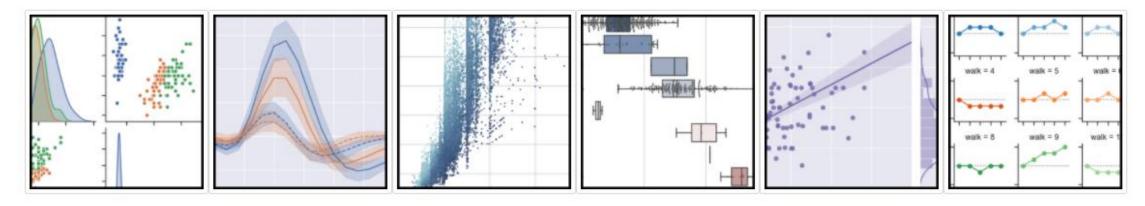


Scatter matrix

```
fig = plt.figure()
ax = fig.add subplot(111)
cax = ax.matshow(corr data, vmin=-1, vmax=1, interpolation='nearest')
                                                                                               - 1.00
fig.colorbar(cax)
                                                   CRIM ZN INDUS CHAS NOX RM AGE DIS RAD TAXPTRATIO B LSTATMEDV
fig.set_size_inches(10,10)
                                               CRIM
                                                                                               - 0.75
ticks= np.arange(0,14,1)
                                                 ΖN
ax.set_xticks(ticks)
                                               INDUS
                                                                                               0.50
ax.set_yticks(ticks)
                                               CHAS
                                                NOX
ax.set_xticklabels(df_data.columns)
                                                                                               - 0.25
                                                RM
ax.set yticklabels(df data.columns)
                                                AGE
                                                                                               - 0.00
                                                DIS
                                                RAD
                                                                                               -0.25
                                                TAX
                                              PTRATIO
                                                                                               -0.50
                                                 В
                                               LSTAT
                                                                                               -0.75
                                               MEDV
```

seaborn

seaborn: statistical data visualization



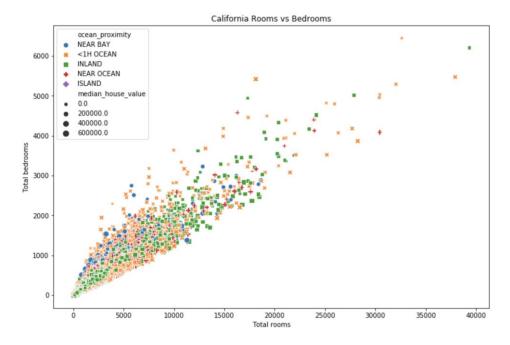
Matplotlib를 더 쉽게!

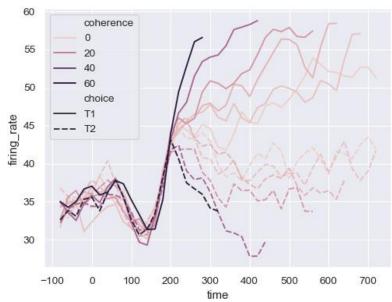
seaborn

- 기존 matplotlib에 기본 설정을 추가
- 복잡한 그래프를 간단하게 만들 수 있는 wrapper
- 간단한 코드 + 예쁜 결과

seaborn

- 기존 matplotlib에 기본 설정을 추가
- 복잡한 그래프를 간단하게 만들 수 있는 wrapper
- 간단한 코드 + 예쁜 결과



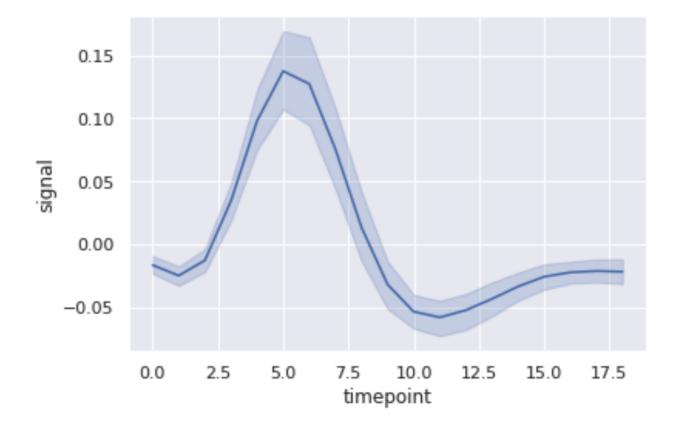


- matplotlib와 같은 기본적인 plot
- 손쉬운 설정으로 데이터 산출
- lineplot, scatterplot, countplot 등

```
sns.lineplot(x="total_bill", y="tip", data=tips)
```

```
# Plot the responses for different events and regions
sns.lineplot(x="timepoint", y="signal", data=fmri)
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a23af3278>

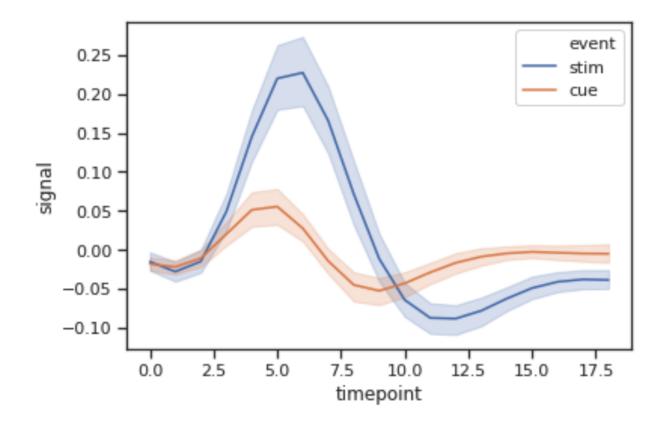


```
1 fmri.sample(n=10, random_state=1)
```

| | subject | timepoint | event | region | signal |
|-----|---------|-----------|-------|----------|-----------|
| 806 | s6 | 18 | cue | parietal | 0.019532 |
| 691 | s5 | 15 | cue | frontal | -0.019507 |
| 148 | s5 | 8 | stim | parietal | 0.006805 |
| 676 | s13 | 0 | cue | parietal | -0.018394 |
| 156 | s11 | 7 | stim | parietal | 0.254042 |
| 27 | s1 | 17 | stim | parietal | -0.038021 |
| 200 | s11 | 4 | stim | parietal | 0.087175 |
| 262 | s3 | 0 | stim | parietal | -0.008576 |
| 94 | s4 | 12 | stim | parietal | -0.090036 |
| 339 | s4 | 5 | stim | frontal | 0.455575 |

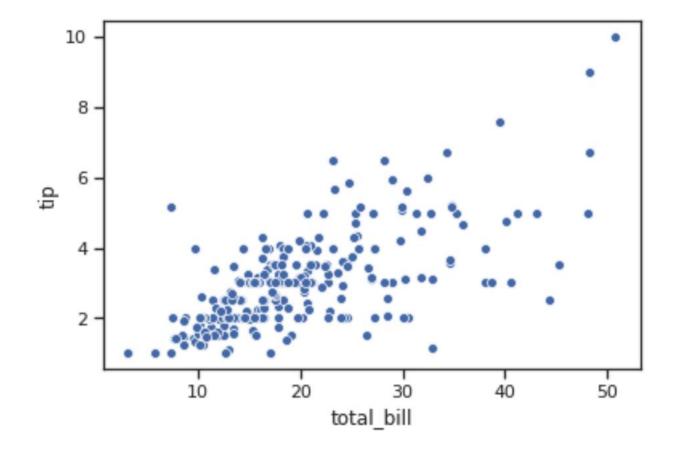
```
1 sns.lineplot(x="timepoint", y="signal", hue="event", data=fmri)
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a24a1bac8>



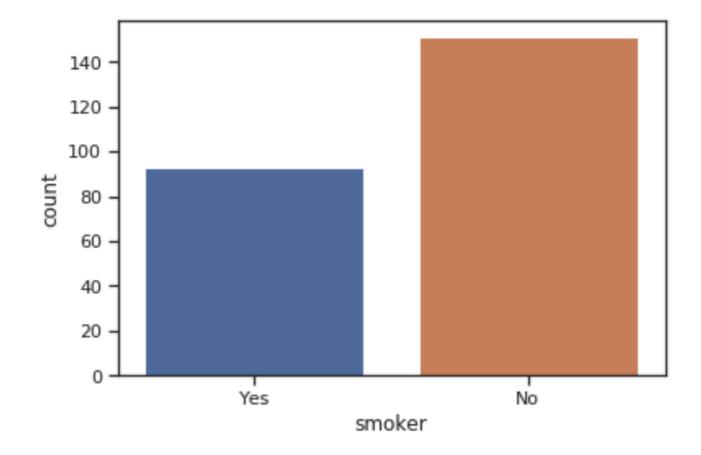
```
1 sns.scatterplot(x="total_bill", y="tip", data=tips)
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a25d37e10>



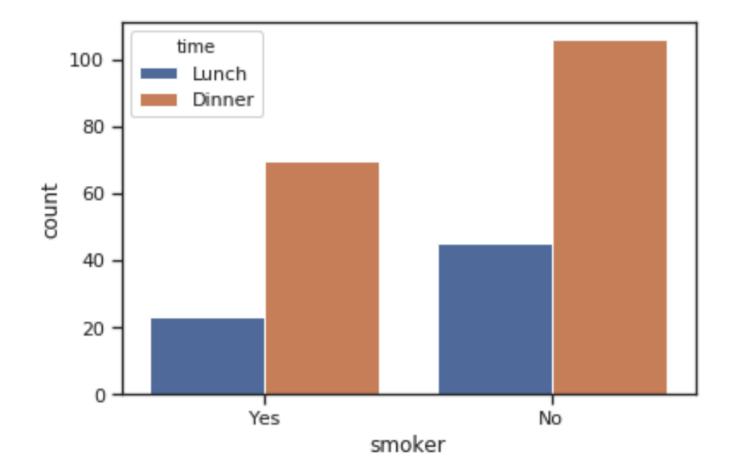
```
1 sns.countplot(x="smoker",data=tips)
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a257d4eb8>



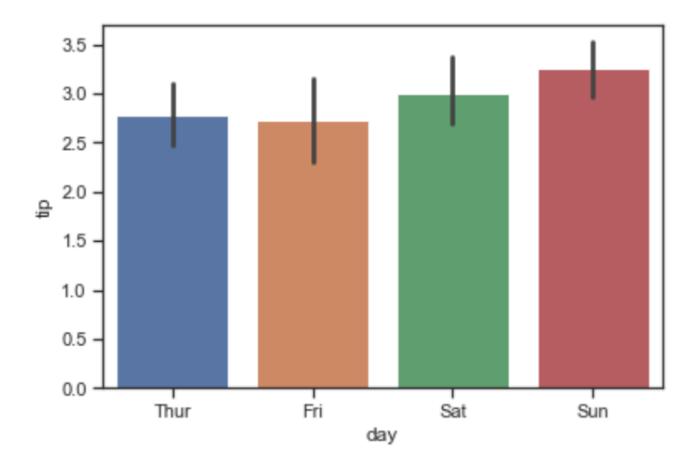
```
1 sns.countplot(x="smoker", hue="time", data=tips)
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a24ef6d30>



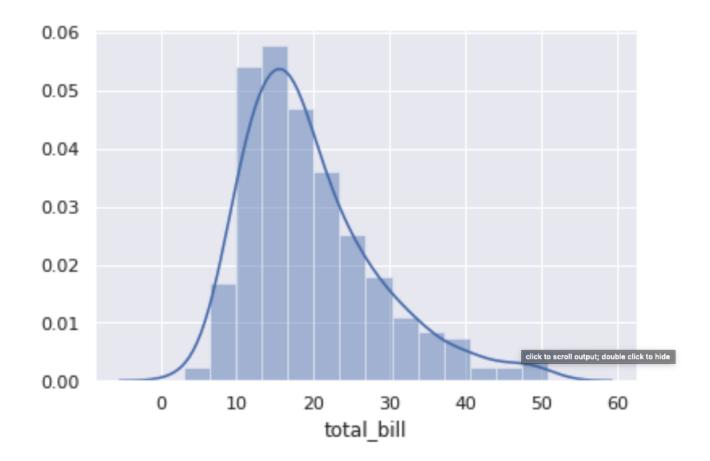
```
sns.barplot(x="day", y="tip", data=tips)
```

<matplotlib.axes._subplots.AxesSubplot at 0x171688f9c08>



```
1 sns.set(style="darkgrid")
2 sns.distplot(tips["total_bill"])
```

<matplotlib.axes._subplots.AxesSubplot at 0x1a26db24a8>



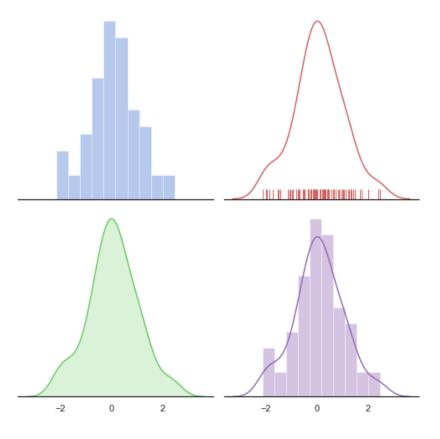
seaborn – predefined plots

- Viloinplot boxplot에 distribution을 함께표현
- Stripplot scatter와 category 정보를 함께 표현
- Swarmplot 분포와 함께 scatter를 함께 표현
- Pointplot categor별로 numeri의 평균, 신뢰구간 표시
- regplot scatter + 선형함수를 함께 표시

seaborn - mutliple plots

- 한 개이상의 도표를 하나의 plot에 작성
- Axes를 사용해서 grid를 나누는 방법

```
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
sns.set(style="white", palette="muted", color_codes=True)
rs = np.random.RandomState(10)
f, axes = plt.subplots(2, 2, figsize=(7, 7), sharex=True)
sns.despine(left=True)
d = rs.normal(size=100)
sns.distplot(d, kde=False, color="b", ax=axes[0, 0])
sns.distplot(d, hist=False, rug=True, color="r", ax=axes[0, 1])
sns.distplot(d, hist=False, color="g", kde_kws={"shade": True}, ax=axes[1, 0])
sns.distplot(d, color="m", ax=axes[1, 1])
plt.setp(axes, yticks=[])
plt.tight_layout()
```



seaborn – predefined mutliple plots

- replot Numeric 데이터 중심의 분포 / 선형 표시
- catplot category 데이터 중심의 표시
- FacetGrid 특정 조건에 따른 다양한 plot을 grid로 표시
- pairplot 데이터 간의 상관관계 표시
- Implot regression 모델과 category 데이터를 함께 표시

SAMSUNG

Data Science Academy